



# Journée Dép. Bios. Montpellier, Juillet 2019



# Plan

## 1. Introduction

## 2. Expériences au Cirad

- Marie-Claude Deboin (Dgdrs-Dist)
- Manuel Ruiz (UMR AGAP, Plateforme SouthGreen)

## 3. Session débat





# Introduction





# Qu'est-ce que c'est ?

*umbrella term for non-traditional **strategies** and **technologies** needed to gather, organize, process, and gather insights from **large** or **complex** datasets*

- **large** : impossible de stocker et/ou processor dans un seul ordinateur
- **complex** : issus de plusieurs sources et fortement structurés
- Trois Vs : **V**olume, **V**elocity, **V**ariety





# D'autres gros mots associés

- **Data science** : Les statistiques adaptés au Big Data (+ informatique)
- **Machine Learning / Intelligence Artificielle** : Méthodes **prédictifs** qui nécessitent (souvent) beaucoup des données d'entraînement





# Ça bouge !

2019:

**Mars - INRA** P. Ezanno et al. *L'Intelligence Artificielle & les Recherches en Santé Animale à l'Inra.*


Rapport du groupe de travail mandaté par le DSA

**Juin - IRD** C. Stephens *Using spatial data to unravel the complexity of emerging diseases.*

Analyse de co-occurrence d'espèces à partir de données du GBIF (*Global Biodiversity Information Facility*)

**Juin - IRD** F. Masseglia. *BIG DATA : Analyser de GRANDS corpus de données scientifiques*





CÉDRIC VILLANI

Mathématicien et député de l'Essonne

## DONNER UN SENS À L'INTELLIGENCE ARTIFICIELLE

POUR UNE STRATÉGIE  
NATIONALE ET EUROPÉENNE

### Composition de la mission

**Marc Schoenauer** Directeur de recherche INRIA • **Yann Bonnet** Secrétaire général du Conseil national du numérique • **Charly Berthet** Responsable juridique et institutionnel du Conseil national du numérique • **Anne-Charlotte Cornut** Rapporteur au Conseil national du numérique • **François Levin** Responsable des affaires économiques et sociales du Conseil national du numérique • **Bertrand Rondepierre** Ingénieur de l'armement, Direction générale de l'armement.

Mars 2018. Mission confiée par le  
Premier Ministre Édouard  
Philippe

*“Dopée par les progrès de  
l’intelligence artificielle,  
la révolution du **big data**  
contribue à rendre le  
monde plus transparent,  
plus quantifiable,  
mesurable à l’infini.”*





# Expériences au Cirad



- **Marie-Claude DEBOIN** (Dgdrs-Dist)

*IST et big data : points de rencontre*



- **Manuel Ruiz** (UMR AGAP, Plateforme SouthGreen)

*Défis liés aux Big Genomics Data*







# Débat





# À la limite

*“This is a world where **massive amounts of data and applied mathematics replace every other tool** that might be brought to bear. Out with every theory of human behavior, from linguistics to sociology. Forget taxonomy, ontology, and psychology. Who knows why people do what they do? The point is they do it, and we can track and measure it with unprecedented fidelity. **With enough data, the numbers speak for themselves.** (...) **We can stop looking for models.** We can analyze the data without hypotheses about what it might show. We can throw the numbers into the biggest computing clusters the world has ever seen and let statistical algorithms **find patterns where science cannot.**”*

Chris Anderson, 2008, Wired<sup>1</sup>

<sup>1</sup>The End of Theory: The Data Deluge Makes the Scientific Method Obsolete. Wired <https://www.wired.com/2008/06/pb-theory/>





# Big noise ?

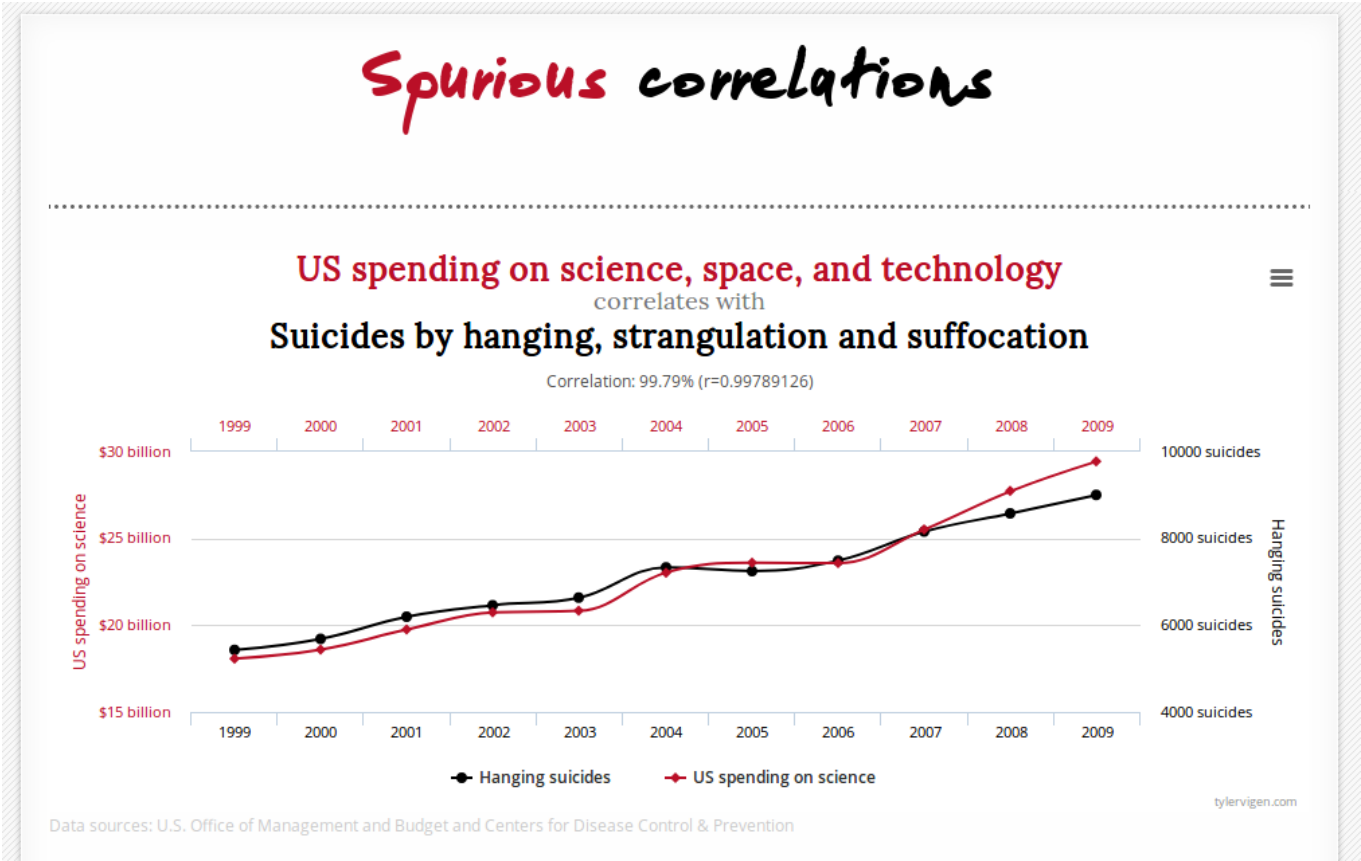
“The rise of **Big Data** has the potential to help us predict the future, yet **much of it is misleading, useless or distracting.**”

Nate Silver, 2013, *The Signal and the Noise*





# Corrélations et causalités





# Quantité vs qualité

Statistics and Probability Letters 136 (2018) 142–145



ELSEVIER

Contents lists available at [ScienceDirect](#)

## Statistics and Probability Letters

journal homepage: [www.elsevier.com/locate/stapro](http://www.elsevier.com/locate/stapro)



### When small data beats big data

Julian J. Faraway, Nicole H. Augustin \*

*Department of Mathematical Sciences, University of Bath, United Kingdom*



#### ARTICLE INFO

Article history:  
Available online 17 February 2018

Keywords:  
Big data  
Small data

#### ABSTRACT

Small data is sometimes preferable to big data. A high quality small sample can produce superior inferences to a low quality large sample. Data has acquisition, computation and privacy costs which require costs to be balanced against benefits. Statistical inference works well on small data but not so well on large data. Sometimes aggregation into small datasets is better than large individual-level data. Small data is a better starting point for teaching of Statistics.

© 2018 Elsevier B.V. All rights reserved.

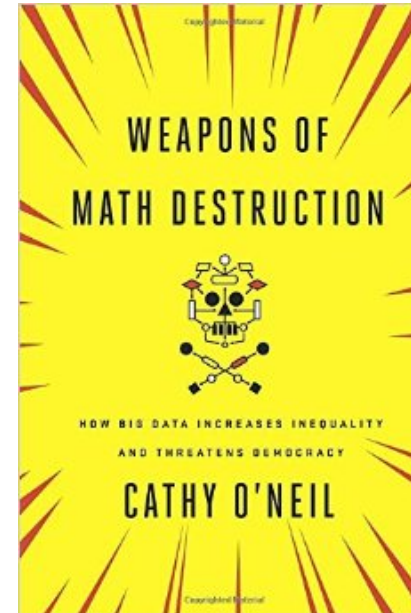




# Data neutrality

*“Not everything that counts can be counted, and not everything that can be counted counts.”*

William Bruce Cameron  
(Sociologist)



*“How Big Data increases inequality and threatens Democracy”*





# Somme-nous préparés ?

*“Don’t sleep on the basics.  
Someone probably solved  
your problem in the 80s.”*

Nick Strayer (2019). **Using AWK  
and R to parse 25tb.**<sup>1</sup>

*“You can have a second  
computer once you’ve  
shown you know how to  
use the first one.”*

F. McSherry, M. Isard, D. G.  
Murray (2015). **Scalability! but  
at what cost ?** *Usenix conference*<sup>2</sup>

<sup>1</sup> [https://livefreeordichotomize.com/2019/06/04/using\\_awk\\_and\\_r\\_to\\_parse\\_25tb/](https://livefreeordichotomize.com/2019/06/04/using_awk_and_r_to_parse_25tb/)

<sup>2</sup> <https://t.co/oV1Qs6zatz>







# Comment se positionner au Cirad / Bios ?

- On réagit au fur et à mesure ? on se **prépare** ? comment ?
- **Infrastructure** logistique ? formation ? partenariat ? collaborations ?
- On devrait tous nous **former** d'avantage à l'analyse de données ?





# Merci !